# Svolgimento esercitazione Data Mining B Classificazione Multi-Classe con classificatori binari

Docente: Michela Antonelli

Alunno: Mario Canalella, matricola 00122833

# Premesse preliminari

Per lo svolgimento della seguente esercitazione ho sviluppo un applicativo Java con interfaccia grafica. Essa permette di selezionare i path dei file CSV in modo da processarli ed analizzarli tramite WEKA.

Per compiere tutto il processo di sviluppo sono stati utilizzati i seguenti componenti software:

- Java 1.8
- Spring Boot 2.6.3
- Weka 3.8.6
- Weka SMOTE 1.0.3
- Maven

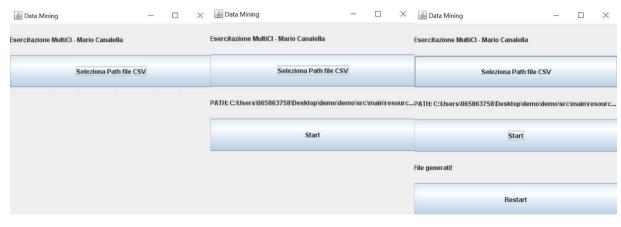
Per poter compilare ed eseguire nella propria macchina l'applicativo software occorre avere installato:

- Java 1.8
- Maven

Ed eseguire nel root della cartella del progetto Java i seguenti comandi nel terminale:

- mvn clean install -U
- ./mvnw -X spring-boot:run

In questo modo l'applicativo partirà senza intoppi.



Esso genererà i report e i risultati della classificazione dentro la cartella "resources/irisSingleCl".

# Svolgimento Esercitazione

#### Punto 1

 Il seguente codice permette di convertire i file CSV presenti nel path selezionato tramite interfaccia nel formato ARFF creando 4 file: 3 file dove Ciascun dataset binario, contenuto nel file i-esimo, ha come istanze della classe positiva tutte le istanze della classe i-esima Ci e le istanze della classe negativa sono tutte quelle delle classi restanti e un quarto file dove sono messe assieme tutte le istanze presenti nei file csv forniti.

```
AtomicInteger index = new AtomicInteger();
  fileNames.forEach(
         file -> {
            ArffSaver saver = new ArffSaver();
                loader.setSource(new File(file));
                data.insertAttributeAt(new Attribute("Class", values),
                for (int i = 0; i < data.numInstances(); i++) {</pre>
                   data.instance(i).setValue(data.numAttributes() - 1,
                data.setRelationName("C" + index);
                saver.setInstances(data);
```

```
strings pos[i] = ((att.type() == Attribute.STRING) ||
                (att.type() == Attribute.NOMINAL));
   Instances multiClasses = new Instances(instances.get(0));
   AtomicReference<String> relationName = new AtomicReference<>("");
        relationName.set(relationName + instance.relationName() + " ");
       values.addElement(instance.relationName());
   multiClasses = getInstances(multiClasses);
    Instances finalMultiClasses = multiClasses;
    instances.stream().skip(1).forEach(
               DataSource source = new DataSource(istance);
                    e.printStackTrace();
                while (source.hasMoreElements(instancs)) {
                    instance = source.nextElement(instancs);
                    finalMultiClasses.add(instance);
finalMultiClasses.instance(finalMultiClasses.numInstances() - 1)
    finalMultiClasses.setRelationName(relationName.toString().substring(0,
relationName.toString().length() - 1));
   ArffSaver saver = new ArffSaver();
       saver.setInstances(finalMultiClasses);
       saver.setFile(new File(PATH + "\\" + "multiClasses" + ARFF));
```

```
e.printStackTrace();
fileNamesArff.forEach(
        fileArff -> {
                data = new Instances(new BufferedReader(new
                            DataSource source = new DataSource(istance);
                            Instance instance;
                            while (source.hasMoreElements(instants)) {
                                data.add(instance);
                                        data.instance(data.numInstances()
                finalFileNamesArff.add(fileArff + FINAL + ARFF);
                e.printStackTrace();
```

```
} catch (IOException ignored) {}

}

);
return finalFileNamesArff;
}
```

## Punto 2

• Si costruisce il classificatore J48 e i modelli vengono valutati in cross validation (5 fold)

```
rivate void stepTwo(List<String> fileNamesArff) {
                   e.printStackTrace();
orivate Instances prepareData(String instanceFile) throws Exception {
```

```
instance.relationName() + "\n\n", true);
    if (withSmote) {
        writer = new BufferedWriter(new
FileWriter("C:\\Users\\065863758\\Desktop\\demo\\src\\main\\resources\\
    irisSingleCl\\resultWithSMOTE" + instance.relationName() + ".txt"));
    } else {
        writer = new BufferedWriter(new
FileWriter("C:\\Users\\065863758\\Desktop\\demo\\src\\main\\resources\\
        irisSingleCl\\result" + instance.relationName() + ".txt"));
    }
    writer.write(result);
    writer.close();
}
```

# Risultati ottenuti

### Classe C1

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,898	0,041	0,917	0,898	0,907	0,862	0,946	0,874	C2
	0,959	0,102	0,949	0,959	0,954	0,862	0,946	0,964	not_C2
Weighted Avg.	0,939	0,082	0,939	0,939	0,939	0,862	0,946	0,934	

### Classe C2

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,959	0,000	1,000	0,959	0,979	0,970	0,980	0,973	C1
	1,000	0,041	0,980	1,000	0,990	0,970	0,980	0,980	not_C1
Weighted Avg.	0.986	0.027	0.987	0.986	0.986	0.970	0.980	0.978	

## Classe C3

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,959	0,031	0,940	0,959	0,949	0,924	0,965	0,916	C3
	0,969	0,041	0,979	0,969	0,974	0,924	0,965	0,976	not_C3
Weighted Avg.									

Dai dati analizzati si nota una precisione non variabile per l'affinità tra dati rilevati e dati recuperati e dall'abbassamento di precisione della classe positiva ne consegue un aumento di quella negativa. Inoltre dall'osservazione dei valori delle classi negative emerge che quest'ultime presentano un'elevata recall, confermata anche dai valori del TPR.

## Punto 3

Analizziamo il classificatore J48 utilizzando il dataset che si ottiene mettendo assieme tutte le istanze presenti nei file csv forniti.

```
private void stepThree() throws Exception {
    J48 j48 = new J48();
orivate void J48Filter(J48 j48, String multiClassesFile) throws Exception {
        ex.printStackTrace();
instance.relationName() + "\n\n", true);
irisSingleCl\\resultWithSMOTE" + instance.relationName() + ".txt"));
        writer = new BufferedWriter(new
irisSingleCl\\result" + instance.relationName() + ".txt"));
private Instances prepareData(String instanceFile) throws Exception {
FileReader(instanceFile)));
   DataSource dataSource = new DataSource(data);
        System.out.println("reset index...");
        instance.setClassIndex(data.numAttributes() - 1);
```

# Classe C1\_C2\_C3

Possiamo notare come nel caso di C1 abbiamo un miglioramento dei valori mentre C2 e C3 un leggero peggioramento per il TRP e la Recall

#### Punto 4

Aggiungiamo il filtro SMOTE alle classi

```
private void stepFour(List<String> fileNamesArff) {
   fileNamesArff.forEach(
           fileArff -> {
                    J48FilterWithSMOTE(j48, fileArff);
private void J48FilterWithSMOTE(J48 j48, String multiClassesFile) throws
       SMOTE smote = new SMOTE();
       smote.setInputFormat(data);
       writer = new BufferedWriter(new
```

# Ottieniamo i seguenti risultati:

## C1

```
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall F-Measure MCC
                                                                       ROC Area PRC Area Class
                0,990 0,000 1,000 0,990 0,995 0,990
                                                                       0,995 0,995
                1,000 0,010 0,990
                                          1,000 0,995
                                                             0,990
                                                                       0,995 0,990
                                                                                           not_C1
              0,995 0,005 0,995 0,995 0,995
                                                             0,990
                                                                       0,995 0,992
Weighted Avg.
C2
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall F-Measure MCC
                                                                     ROC Area PRC Area Class

    0,939
    0,041
    0,958
    0,939
    0,948
    0,898

    0,959
    0,061
    0,940
    0,959
    0,949
    0,898

    0,949
    0,051
    0,949
    0,949
    0,949
    0,898

                                                             0,898 0,949
0,898 0,949
                                                                               0,954
                                                                                0,917
                                                                                         not_C2
                                                             0,898 0,949
Weighted Avg.
                                                                               0,936
C3
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall F-Measure MCC
                                                                       ROC Area PRC Area Class
                0,949 0,041 0,959 0,949 0,954 0,908
                                                                       0,946 0,912
                                                                                          C3
                0,959 0,051 0,949
                                           0,959 0,954
                                                              0,908
                                                                       0,946 0,933
                                                                                          not C3
                0,954 0,046 0,954
                                          0,954 0,954 0,908
                                                                       0,946 0,923
Weighted Avg.
```

Di cui notiamo che utilizzando il filtro SMOTE e ribilanciando la classe positiva si ha miglioramento della precisione solo nel caso della classe positiva C1.

#### Punto 5

Costruiamo 2 metaclassificatori che inglobino ciascuno un metodo diverso di attribute selecion (infogain+ ranker (valore infogain >0) e cfsSubsetEval+ best first) applicando a ciascuno il filtro SMOTE.

```
rivate void stepFive(List<String> fileNamesArff) {
   fileNamesArff.forEach(
           fileArff -> {
                   e.printStackTrace();
rivate void metaClassifiersInfogainRanker(String classFile) throws Exception
   Instances data = prepareData(classFile);
  SMOTE smote = new SMOTE();
  AttributeSelectedClassifier classifier = new
  NaiveBayes nb = new NaiveBayes();
  Evaluation evaluation = new Evaluation(data);
  writer.write(result);
  writer.close();
  saver.setFile(new
```

```
getAttributeSelectorInfogainRanker(eval, ranker, data);
}
private void getAttributeSelectorCfsSubsetEvalBestFirst (CfsSubsetEval
evaluator, BestFirst search, Instances data) throws Exception {
   AttributeSelection selector = new AttributeSelection();
   selector.setEvaluator(evaluator);
   selector.SelectAttributes(data);
   writer = new BufferedWriter(new
FileWriter("C:\\Users\\055863758\\Desktop\\demo\\demo\\src\\main\\resources\\
irisSingleCl\\selettoriCfsSubsetEval" + data.relationName() + ".txt"));
   writer.write("Selettori CfsSubsetEval + BestFirst data " +
data.relationName() + "\n\n");
   writer.write(Arrays.toString(selector.selectedAttributes()));
   writer.close();
}
private void getAttributeSelectorInfogainRanker(InfoGainAttributeEval
evaluator, Ranker ranker, Instances data) throws Exception {
   AttributeSelection selector = new AttributeSelection();
   selector.setEvaluator(evaluator);
   selector.setEvaluator(evaluator);
   selector.selectAttributes(data);
   writer = new BufferedWriter(new
FileWriter("C:\\Users\\055863758\\Desktop\\demo\\demo\\src\\main\\resources\\
irisSingleCl\\selettoriInfogainRanker" + data.relationName() + ".txt"));
   writer.write("Selettori Infogain + Ranker data " + data.relationName() +
"\n\n");
   writer.write(Arrays.toString(selector.selectedAttributes()));
   writer.close();
}
```